

**Universidad Nacional del Altiplano**

**Facultad de Ingeniería Estadística e Informática**

**Docente:** Fred Torres Cruz

**Autor :** Ronald Junior Pilco Nuñez

## **Trabajo Encargado - N° 007**

### **Resolución de Ejercicios de Descenso del Gradiente**

**Github**

Repositorio

### **Ejercicio 1: Mínimo de una Función Cuadrática en 1D**

#### **Enunciado**

Minimiza la función  $g(x) = (x - 5)^2$  empezando en  $x_0 = 10$ , con tasa de aprendizaje  $\eta = 0.2$ . Realiza 5 iteraciones manualmente:

$$x_{k+1} = x_k - 0.2 \cdot \frac{d}{dx}g(x_k).$$

Anota en una tabla los valores  $(k, x_k, g(x_k))$  para cada paso. Explica por qué el resultado tiende a  $x = 5$ .

#### **Solución**

La derivada de  $g(x)$  es:

$$\frac{d}{dx}g(x) = 2(x - 5).$$

Aplicando el descenso del gradiente, las iteraciones son:

Iteración $k$	$x_k$	$g(x_k)$
0	10.0	25.0
1	8.0	9.0
2	6.8	3.24
3	6.08	1.1664
4	5.664	0.4199
5	5.3984	0.1512

Table 1: Iteraciones del descenso del gradiente para  $g(x) = (x - 5)^2$ .

El resultado tiende a  $x = 5$  porque es el mínimo de la función  $g(x)$ . El descenso del gradiente ajusta  $x_k$  en la dirección opuesta al gradiente, que apunta hacia el mínimo.

## Ejercicio 2: Ajuste de una Recta con Descenso del Gradiente

### Enunciado

Ajusta la recta  $h(x) = \beta_0 + \beta_1 x$  minimizando:

$$J(\beta_0, \beta_1) = \sum_{i=1}^5 (y_i - (\beta_0 + \beta_1 x_i))^2$$

mediante descenso del gradiente. Usa  $\eta = 0.01$  y realiza al menos 3 iteraciones para actualizar  $\beta_0$  y  $\beta_1$ . Muestra en cada iteración los nuevos valores de  $(\beta_0, \beta_1)$  y el costo  $J$ .

### Solución

Los gradientes de  $J$  respecto a  $\beta_0$  y  $\beta_1$  son:

$$\frac{\partial J}{\partial \beta_0} = -2 \sum_{i=1}^5 (y_i - (\beta_0 + \beta_1 x_i)),$$

$$\frac{\partial J}{\partial \beta_1} = -2 \sum_{i=1}^5 (y_i - (\beta_0 + \beta_1 x_i)) x_i.$$

Inicializamos  $\beta_0 = 0$  y  $\beta_1 = 0$ . Las iteraciones son:

Iteración $k$	$\beta_0$	$\beta_1$	$J(\beta_0, \beta_1)$
0	0.0	0.0	63.5
1	0.127	0.254	48.23
2	0.242	0.482	36.67
3	0.346	0.686	28.01

Table 2: Iteraciones del descenso del gradiente para ajustar la recta.

## Ejercicio 3: Clasificación Logística con Descenso del Gradiente

### Enunciado

Define un modelo de clasificación logística  $\sigma(\mathbf{w}^\top \mathbf{x})$  y la función de costo logístico. Inicia con pesos  $\mathbf{w}_0 = (0, 0, 0)$  (incluyendo el sesgo como componente adicional). Aplica 3 iteraciones de descenso del gradiente con  $\eta = 0.1$ . Muestra las actualizaciones y cómo disminuye el error de clasificación (o el valor de la función de costo) en cada paso.

### Solución

La función de costo logístico es:

$$J(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\sigma(\mathbf{w}^\top \mathbf{x}_i)) + (1 - y_i) \log(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))],$$

donde  $\sigma(z) = \frac{1}{1+e^{-z}}$ .

Las actualizaciones de los pesos son:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla J(\mathbf{w}_k).$$

Iteración $k$	$\mathbf{w}_k$	$J(\mathbf{w}_k)$
0	(0.0, 0.0, 0.0)	0.6931
1	(0.025, 0.05, 0.075)	0.6823
2	(0.048, 0.096, 0.144)	0.6718
3	(0.069, 0.138, 0.207)	0.6616

Table 3: Iteraciones del descenso del gradiente para clasificación logística.

## Ejercicio 4: Descenso del Gradiente Estocástico (SGD)

### Enunciado

Explica cómo aplicarías SGD tomando un minibatch de 50 datos en cada iteración y describe por qué este procedimiento puede converger más rápido en la práctica que el descenso por lotes completos (batch gradient descent). Para guiar el cálculo, utiliza una tasa de aprendizaje  $\eta = 0.01$  y muestra, al menos de forma hipotética, cómo se modificarían los parámetros  $\mathbf{w}$  tras varias iteraciones sobre distintos minibatches.

## Solución

En SGD, en cada iteración se selecciona un minibatch de 50 datos y se actualizan los pesos  $\mathbf{w}$  usando el gradiente calculado sobre ese minibatch:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla J_{\text{minibatch}}(\mathbf{w}_k).$$

Este método converge más rápido porque las actualizaciones son más frecuentes y ruidosas, lo que permite escapar de mínimos locales y converger más rápidamente en problemas de alta dimensión.

Iteración $k$	$\mathbf{w}_k$
0	(0.0, 0.0, 0.0)
1	(0.01, 0.02, 0.03)
2	(0.019, 0.038, 0.057)
3	(0.028, 0.056, 0.084)

Table 4: Iteraciones hipotéticas de SGD con minibatches de 50 datos.